

GENA-LM

анализ и развитие

Открытое семейство ДНК-моделей от AIRI, опубликованное в Nucleic Acids Research в 2025 году.

ПОЛНЫЙ РАЗБОР С ИНТЕРАКТИВНЫМИ ГРАФИКАМИ

eugenekywalker.github.io/GENA_LM_AIRI/

1 • МЕТОД СТАТЬИ

GENA-LM — открытое семейство ДНК-моделей от AIRI, опубликованное в Nucleic Acids Research в 2025 году. До неё ДНК-модели видели только короткие участки: DNABERT — 512 нуклеотидов, Nucleotide Transformer — 12 000. Регуляторные элементы, влияющие на гены с расстояния 100 000 букв, в такое окно не попадают. GENA-LM работает с участками **до 36 000 нуклеотидов сразу**, а с рекуррентной памятью — до миллионов.

Главная техническая идея — не одно изобретение, а пайплайн из четырёх готовых компонентов, который впервые работает для длинных ДНК-последовательностей. Новизна — в их комбинации.

- **BPE-токенизация вместо k-mers.** Словарь на 32 000 «слов» переменной длины (медиана 9 нт). В стандартное окно влезает в 8–10 раз больше ДНК.
- **BERT-архитектура с masked language modeling.** 15 % токенов прячутся — модель угадывает их по соседям. Никакой биологической разметки, только сама ДНК.
- **Sparse attention из BigBird.** Локальные + случайные + глобальные связи. Длина входа вырастает с 4.5 до 36 кб.
- **Recurrent Memory Transformer (RMT).** Длинная последовательность режется на сегменты по 4.5 кб; 10 memory-токенов «впитывают» прочитанное и передаются дальше — до миллионов нуклеотидов.

Данные — сборка T2T-CHM13v2 (полный геном человека, включая центромеры и теломеры) с вариантами из 1000 Genomes. Для мультимодовых моделей — геномы мыши, дрозофилы, нематоды, дрожжей и десятков других эукариот.

2 • КЛЮЧЕВЫЕ ЗАДАЧИ

Семейство из **8 предобученных моделей** — base (110 млн параметров) и large (336 млн), плюс варианты с BigBird и RMT. Все веса, код, Colab и веб-сервис *dnalm.airi.net* — в открытом доступе. Авторы оценивают модели на **9 биологических задачах**, например «это промотор?». В моих экспериментах ниже я использую 4 из них: промоторы, энхансеры, открытая ДНК, кодирующие участки.

3 • СИЛЬНЫЕ СТОРОНЫ

- **Открытость по полной программе.** 8 моделей на HuggingFace, код, Colab, веб-сервис.
- **Действительно длинный контекст.** На момент выхода — самая длинноконтекстная ДНК-модель на трансформере.
- **Cross-species transfer.** F1 $\approx$ 0.95 на близких млекопитающих без переобучения.
- **Учит биологию.** Сама выделяет мотивы транскрипционных факторов — ATF1, GATA2, CTCF.

4 • СЛАБЫЕ СТОРОНЫ

- **Один токен $\approx$ 9 нуклеотидов.** Точечные мутации почти не видны: AUC 0.66 на ClinVar SNV.
- **Не везде побеждает.** На промоторах в окне 300 п. о. проигрывает DNABERT, на сплайсинге — SpliceAI.
- **Хрупкая инфраструктура.** Sparse attention требует CUDA + Triton + DeepSpeed; ломается между версиями драйверов.
- **Нет сравнения с SSM.** Caduceus и Evo появились почти одновременно — но их в работе нет.

Авторы дообучали модель под каждую задачу и читали ответ только с последнего слоя. Я проверил, что находится внутри модели *до* дообучения и на других слоях.

5.1 · ЧТО ЗНАЕТ КАЖДЫЙ СЛОЙ

Не читай последний слой.

Снял эмбединги с каждого из 12 слоёв (плюс с входа L0), проверил на 4 задачах. **Биология модели живёт в середине** — около 4–5 слоя. Promoter: L4 = 0.809 vs L12 = 0.778. Coding: L5 = 0.915 vs L12 = 0.887.

5.2 · GENA-LM VS HYENADNA

Маленькая модель «победила» большую. Спойлер — нет.

GENA-LM против HyenaDNA, которая в ~280 раз меньше по числу параметров. С последнего слоя HyenaDNA выигрывает 3 из 4 задач. С лучшего слоя на каждую задачу — GENA-LM возвращает себе 3 победы. **Вывод сравнения меняется в зависимости от выбора слоя.**

5.3 · ПРОВЕРКА ПРИЧИНЫ

Модель выучила биологию, а не запомнила «редкие буквы».

Поменял буквы внутри мотива CTCF (биологически важный участок) — модель сильно реагирует, $r = 0.893$ с PWM-важностью. В случайных местах вне мотива — почти не реагирует. **Разница 15×**. Это исключает гипотезу «реагирует на любые редкие токены».

6 · ЧТО ПРЕДЛАГАЮ РАЗВИТЬ

Лучший слой — не последний.

GENA-LM из середины обходит HyenaDNA на 3 задачах из 4. С последнего слоя — проигрывает.



Сделать «лучший слой» стандартом.

Измерять ДНК-модели по их лучшему слою, не последнему. Ожидаемый эффект: +3–5 % точности.

Модель действительно знает биологию.

15× разница между важными и случайными местами. Это не угадывание.



Повторить тест на других участках.

Ещё 3 биологических сигнала и другие ДНК-модели. Общее ли это свойство — или повезло с CTCF.

РАЗБИРАЕМАЯ СТАТЬЯ

Fishman V., Kuratov Y., Shmelev A., Petrov M., Penzar D., Shepelin D., Chekanov N., Kardymon O., Burtsev M. *GENA-LM: a family of open-source foundational DNA language models for long sequences*. Nucleic Acids Research **53**(2), gkae1310 (2025). [doi:10.1093/nar/gkae1310](https://doi.org/10.1093/nar/gkae1310)

Код: github.com/eugenekywalker/GENA_LM_AIRI